

Wolniak

Florian

Projet d'économétrie

Question 1 :

Le concept d'efficience informationnelle est un concept essentiel dans la littérature économique et plus précisément financière. Il est ainsi primordial d'en comprendre les aboutissants et de savoir comment respecter cette efficience. Dans un premier temps il est nécessaire de comprendre ce que l'on recherche. L'efficience informationnelle a été initialement introduit par FAMA (1965) stipulant qu'un marché est efficient si les prix des actifs reflètent pleinement et instantanément toute l'information disponible, empêchant ainsi tout abus de position et de rentabilité lié à l'information. JENSEN (1978) assouplira cette définition en définissant l'efficience informationnelle en stipulant qu'un investisseur ne peut pas faire de profit anormal avec l'information disponible. Évidemment les marchés sont rarement binaires, il existe ainsi différents niveaux d'efficience. C'est à partir des travaux de FAMA (1965), que Lardic et Mignon vont distinguer trois formes d'efficience. Nous retrouverons ainsi :

- L'efficience forte : les prix intègrent toute l'information, même privée
- L'efficience semi-forte : les prix intègrent toute l'information publique
- L'efficience faible : les prix intègrent parfaitement toute l'information contenue dans les cours passés. Ici donc on ne peut pas effectuer des profits en se basant sur les prix historiques.

Ce sera sur la forme faible que se concentra notre projet. Mathématiquement cela implique que les cours boursiers suivent un processus de marché aléatoire, et que les rentabilités sont des variables aléatoires indépendantes.

Comme toute étude économétrique et statistiques, il est nécessaire d'effectuer des tests statistiques permettant de vérifier nos hypothèses de départ. Dans notre cas, on cherchera à vérifier empiriquement l'hypothèse d'efficience faible, notamment via des tests de non-prévisibilité ou de marche aléatoire. Comme le montre Stachowiak dans ses nombreuses études, la littérature scientifique utilise un florilège de tests, nous donnant ainsi :

- Les tests de racine unitaire, notamment celui de Dicker-Fuller augmenté, sont des tests permettant de déterminer si notre variable est non-stationnaire (Avec une intégration d'ordre 1). C'est une condition nécessaire à l'affirmation d'une éventuelle marche aléatoire. Inversement, si l'hypothèse est rejetée alors la variable possède une racine unitaire.

- Les tests d'autocorrélation linéaire, notamment le test de Box-Pierce ou Ljung-Box, sont des tests cherchant à exploiter les fonctions d'autocorrélation, partielle ou non (ACF et PACF). Le but de ces tests sont de savoir si, par exemple les rendements passés ont un pouvoir explicatif sur les rendements actuels. L'ajustement d'algorithme ARIMA permet de voir si une structure autorégressive (AR) ou de moyenne mobile (MA) se dégage significativement de notre série. Cela nous permet de savoir si notre série est purement déterminée par ses valeurs passées ou par des chocs exogènes supplémentaire.
- Les tests de ratio de variance, notamment celui de Lo et MacKinlay ou de Cochrane, sont des tests permettant de déterminer la présence d'une marche aléatoire. Mathématiquement ils cherchent à savoir si une variance sur n périodes est égale n fois la variance sur une période. Ainsi si l'on rejette l'hypothèse alors on admet qu'il existe une autocorrélation des variables et donc éventuellement une influence à un retour à une moyenne.
- Le test ARCH est un test un peu plus atypique. Ce test se fonde essentiellement sur ce qu'on appelle des "grappes de variances". En d'autres termes, l'effet ARCH est un effet cherchant à déterminer une prévisibilité dans une série à partir d'une moyenne imprévisible. Il stipule que certaines variables disposent d'une hétéroscédasticité conditionnelle, que certaines variables subissent des chocs qui vont, par une certaine logique, provoquer d'autres chocs et inversement si la variable profite d'une période calme.

Nous venons donc de définir les principaux tests qui nous seront utiles pour la détermination d'une efficience faible informationnelle. Cependant ils existent d'autres méthodes qui peuvent s'avérer utiles à ce type d'analyse comme les tests non paramétriques avec les tests des runs ou des filtres. Nous aurons aussi une approche de long terme avec une supposition de retour à la moyenne des variables (Summers, FAMA et French). Enfin nous pourrions retrouver aussi la cointégration si l'on souhaite aller plus loin.

Question 2 :


Dans cette section, nous allons passer à l'aspect pratique sur des indices financiers, le tout sur R. Ainsi avant toute démarche pratique, il faut sélectionner les variables avec lesquelles on va travailler. Pour ce choix, nous nous tournerons vers les indices boursiers Nikkei 225, qui représente le CAC40 japonais, ou l'indice boursier japonais. C'est un marché très intéressant par son histoire macroéconomique, dépendant surtout de sa forte culture, mais aussi par son récent retour en force. Nous sélectionnerons en seconde variable, celle de l'ETF iShares Global Clean Energy. Un ETF est une réplique indicielle, donc c'est à peu près comme si nous nous servions d'un indice boursier. Cet indice se base essentiellement sur le marché énergétique renouvelables, et c'est très intéressant car c'est un marché assez récent qui présente une structure relativement différente car très soumise aux réglementations et intérêts collectifs. L'étude de leurs prévisibilités est particulièrement intéressante pour comprendre les aboutissants de tels marchés "atypiques".

Passons ensuite au code R et à la pratique du test de Dicker-Fuller augmenté. Pour cela nous extrairons les données sur R sur le site Yahoo finance à l'aide "getSymbols". Afin d'obtenir des résultats exploitables nous utiliserons les données à disposition sur 10 ans afin d'obtenir à minima 100 observations, rendant l'étude plus exhaustive. Ensuite nous effectuerons une première forme de nettoyage en ne prenant seulement les prix des actions par leurs prix de clôture ajustés, cela permettra de supprimer le bruit des variations quotidiennes des actions, notamment des mouvements d'actions par fractionnement d'actions ou encore de mouvements de capitaux propres qui in fine reviendrait aux poches de l'investisseur. Par la suite nous effectuerons un second nettoyage permettant de supprimer les valeurs manquantes. Par la suite nous effectuerons, conformément à la littérature financière, nous calculerons la rentabilité continue ou log-rendement des rentabilités des actions, en appliquant une différence de premier ordre, Soit :

$$R_t = \ln(P_t/P_{(t-1)}) = \ln(P_t) - \ln(P_{(t-1)})$$

Cette méthode de calcul est importante car elle permet de calculer la variation, en pourcentage, entre le prix d'hier et d'aujourd'hui. C'est nécessaire avant l'utilisation du test de Dicker-Fuller. En effet cette méthode mathématique, très courante et appréciée en finance, permet de "d'aplatir" la série, permettant ainsi à cette dernière d'osciller autour de 0. Rendant l'étude de sa variance et donc de sa prévisibilité plus intuitive. Cela rend la série théoriquement plus stable et constante. L'utilité du log népérien réside aussi dans sa simplicité d'utilisation, notamment pour le calcul des rentabilités, en transformant un calcul qui se multiplie dans le temps en une simple additivité.

Après application du log-rendement nous obtenons donc ce graphique illustratif de ce que l'on vient d'expliquer :



Nous passons ensuite au test de Dicker-Fuller augmenté, permettant comme expliquer avant de vérifier la stationnarité de nos séries. Avec :

- H_0 : l'hypothèse postulant de la présence d'une racine unitaire
- H_1 : l'hypothèse postulant d'une stationnarité

Cependant le test de Dicker-Fuller augmenté se base sur 3 modèles, avec des caractéristiques différentes :

- Le modèle 3 est un modèle possédant une tendance et une constante. C'est le modèle le plus dense et souvent le plus préconisé car plus précis.
- Le modèle 2, ne disposant seulement d'une constante mais pas de tendance.
- Le modèle 1 ne disposant ni de constante ou de tendance.

La constante définit la valeur à partir de laquelle, la série oscille autour sur le long terme. Tandis que la tendance désigne la croissance de cette constante.

Dans notre cas, étant donné que nous utilisons une méthode de log-rendement et à partir des graphiques que nous avons obtenu, le modèle 1 semble amplement suffire à notre étude. En effet, graphiquement, on remarque que les séries oscillent autour de 0 sans vraiment que cette moyenne croît. Nous utiliserons donc le modèle 1.

Pour effectuer le test on utilisera les commandes "testADF" avec comme "type = "none", déterminant l'utilisation du modèle 1. Nous appliquerons ensuite l'utilisation de la méthode du critère d'information d'Akaike ("AIC") afin de déterminer le nombre de retards (p) optimale à l'étude de stationnarité.

Nous obtenons ainsi, pour les indices Nikkei 225 et l'ETF ICLN, respectivement :

```
Test regression none

Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)

Residuals:
    Min       1Q   Median       3Q      Max
-0.11578 -0.01339  0.01212  0.04370  0.14061

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
z.lag.1         -1.0048    0.1163  -8.640 1.19e-14 ***
z.diff.lag      0.0475    0.0842   0.564  0.574
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.04946 on 139 degrees of freedom
Multiple R-squared:  0.482,    Adjusted R-squared:  0.4746
F-statistic: 64.67 on 2 and 139 DF,  p-value: < 2.2e-16

Value of test-statistic is: -8.6403

Critical values for test statistics:
      1pct  5pct 10pct
tau1 -2.58 -1.95 -1.62
```

```

Test regression none

Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)

Residuals:
    Min       1Q   Median       3Q      Max
-0.277059 -0.041294  0.006069  0.049268  0.179439

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
z.lag.1      -0.91582     0.11791  -7.767 1.59e-12 ***
z.diff.lag   -0.03147     0.08540   -0.368   0.713
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.07725 on 139 degrees of freedom
Multiple R-squared:  0.4717,    Adjusted R-squared:  0.4641
F-statistic: 62.05 on 2 and 139 DF,  p-value: < 2.2e-16

Value of test-statistic is: -7.767

Critical values for test statistics:
      1pct  5pct 10pct
taul -2.58 -1.95 -1.62

```

La règle de décision du test ADF est que nous rejetons H_0 si la t-stat calculé < t-stat de référence

D'après nos résultats nous remarquons, pour le Nikkei 225, que statistique de test de ADF est de -8.6403 et que les valeurs statistiques de notre modèle, de références sont -2.58 (1%), -1.95 (5%) et -1.62 (10%). On a donc $-8.6403 < -2.58$; -1.95 ; -1.62 . Cela signifie qu'à n'importe quel degré de confiance la statistique calculée est bien inférieure aux statistiques de référence, nous permettant de rejeter l'hypothèse H_0 et d'assumer une stationnarité de la série Nikkei 225.

Pour la série de l'ETF ICLN, le raisonnement est le même et nous rejetons aussi l'hypothèse H_0 , démontrant d'une stationnarité de la série.

Ces résultats sont donc bien en adéquation avec nos observations initiales des graphiques. Nos séries gravitent autour d'une moyenne et ne suivent aucune tendance. Tout cela n'a pas non plus nécessité d'intégration, ce qui signifie qu'ils sont stationnaire d'ordre 0 I (0).

Ces résultats sont importants et intéressants car ils sont une condition sine qua non de la théorie des marchés efficient de FAMA (1965) stipulant que les prix boursiers suivent une marche aléatoire, et que donc il est nécessaire d'avoir des séries stationnaires, sinon les valeurs futures pourraient être interprétable par leurs valeurs passées. Ainsi à partir d'ici, on suppose que l'écart entre les prix de T et $T-1$ sont déterminer par des chocs exogènes

imprévisibles. Il n'y a donc pas d'abus de rentabilité possible par l'information privée ou publique.

Question 3 :

Désormais nous cherchons à connaître si il y a une présence d'un effet ARCH dans notre modèle. Pour rappel, l'effet ARCH (auto regressive conditionnal hétéroscédasticité) stipule la présence de ce qu'on appelle des "grappes de volatilité". Cela signifie que dans la réalité financière, la majorité des indices boursiers subissent en général des périodes de forte turbulence. Ici nous cherchons donc, bien que la moyenne des rendements soit imprévisible, une certaine prévisibilité de la variance. Par exemple, pendant une période chute du cours, on remarque souvent qu'à la période suivante, le cours chute encore mais moins drastiquement, et inversement on remarque que pendant une période calme (peu volatile), la période suivante est aussi calme. On veut donc savoir si nos variances ont cette mémoire de court terme et donc qu'elles soient conditionnées par le passé.

Pour cela nous appliquerons le test ARCH, avec comme hypothèse :

- Hypothèse nulle H_0 , signifie absence d'effet ARCH (la variance est constante et il y a homoscedasticité conditionnelle)
- Hypothèse alternative H_1 , signifie la présence d'un effet ARCH

Pour la règle de décision, on déterminera la p-value et on la comparera au taux de 5%, si elle est inférieure alors on rejette H_0 et inversement.

Maintenant que nous savons comment fonctionne ce test, il nous suffit de l'appliquer sur R. Cependant nous utiliserons une méthodologie spécifique, comme expliquer précédemment on cherche à connaître s'il y a un effet ARCH, et cet effet est possible qu'à court terme. Ainsi nous testerons le modèle sur des durées allant du très court terme à du court terme plus lointain. Nous le verrons dans le code R avec deux tests pour chaque série de 1 mois et de 3 mois afin de s'assurer que nous testons correctement la présence d'un effet ARCH.

Nous obtenons donc pour les deux séries respectives (Nikkei 225 et ICLN) :

```

--- Test ARCH sur les log-rendements du NIKKEI 225 ---
> ArchTest_N225_lag1 <- ArchTest(Rendement_N225, lags = 1)
> print(ArchTest_N225_lag1)

      ARCH LM-test; Null hypothesis: no ARCH effects

data:  Rendement_N225
Chi-squared = 0.81676, df = 1, p-value = 0.3661

>
> ArchTest_N225_lag3 <- ArchTest(Rendement_N225, lags = 3)
> print(ArchTest_N225_lag3)

      ARCH LM-test; Null hypothesis: no ARCH effects

data:  Rendement_N225
Chi-squared = 1.4212, df = 3, p-value = 0.7006

```

```

--- Test ARCH sur les log-rendements de l'ETF ICLN ---
> ArchTest_ICLN_lag1 <- ArchTest(Rendement_ICLN, lags = 1)
> print(ArchTest_ICLN_lag1)

      ARCH LM-test; Null hypothesis: no ARCH effects

data:  Rendement_ICLN
Chi-squared = 1.2512, df = 1, p-value = 0.2633

>
> ArchTest_ICLN_lag3 <- ArchTest(Rendement_ICLN, lags = 3)
> print(ArchTest_ICLN_lag3)

      ARCH LM-test; Null hypothesis: no ARCH effects

data:  Rendement_ICLN
Chi-squared = 3.7584, df = 3, p-value = 0.2888

```

Comme décrit par le code R, il n'y a visiblement pas d'effet ARCH pour nos deux indices. On le voit à la p-value qui est supérieur à 0.05.

Cela signifie concrètement qu'à la survenue d'un krach de l'indice, rien n'indique que le krach perdurera et inversement en zone calme. Cependant il est important de noter que cela était prévisible du fait de notre utilisation en donnée mensuelle de nos indices. Une utilisation en donnée mensuelle a tendance à lisser les chocs et donc l'effet ARCH, qui est généralement un effet qui se retrouve dans les variables en données journalières.

Question 4 :

Dans cette section nous allons nous concentrer sur le test de Box-Jenkins. Mais tout d'abord il est important de comprendre pourquoi nous utilisons ce test. Dans les fait ce test est très intéressant pour répondre à notre problématique des marchés efficient. Ce test va plus loin que ce qu'on a vu précédemment. En effet, il cherche même à partir des résultats que l'on obtiendra une prévision des rendements futurs. Et c'est en ce point-là que ce test est nécessaire, il nous permettra de déterminer si oui ou non un modèle est prédictible ou non, et ainsi savoir si l'on dispose d'un marché informationnel efficient au sens faible.

Le test de Box-Jenkins se base sur le modèle ARIMA, que nous utilisons. Le modèle ARIMA se dénombre ainsi :

- AR signifie auto-regressive, et est représenté par l'ordre p , soit une unité de mesure permettant de savoir si les valeurs du passé influencent la valeur d'aujourd'hui.
- I signifie integrated, et est représenté par l'ordre d , il détermine le nombre de fois nécessaire qu'il faut pour différencier notre pour le rendre stationnaire.
- MA signifie moving average, et est représenté par l'ordre q , il explique à quel points les chocs/erreurs influencent les valeurs d'aujourd'hui.

Dans notre cas, nous avons vu que nos variables étaient stationnaires avec la méthode du log-rendement sans avoir besoin de le différencier et nous permet donc de définir $d=0$.

Le test de Box-Jenkins se déroule en quatre grandes étapes, dont on détaillera seulement les trois premières.

1ère étape : L'identification


Dans cette partie, nous cherchons à déterminer les ordres p et q , défini précédemment. Pour cela nous devons nous servir d'une analyse de deux graphiques :

- L'ACF, ou la fonction d'autocorrélation, nous permet de nous donner des indices sur l'ordre q de la partie MA
- La PACF, ou la fonction d'autocorrélation partielle, nous permet de nous des indices sur l'ordre p de la partie AR.

La grande différence entre ces fonctions réside dans leurs fonctionnements. L'ACF permet d'étudier le niveau de corrélation globale entre deux périodes. Tandis que la PACF permet d'étudier seulement le niveau de corrélation entre deux périodes sans les valeurs intermédiaire et donc sans bruit.

L'objectif de l'analyse de ces deux fonctions est de trouver des valeurs qui vont en dehors de l'intervalle de confiance.

Cette étape sera donc définie par la fonction ACF ET PACF sur R.



2ième étape : L'estimation

Une fois que nous avons obtenu les modèles ARMA potentiels, il nous faut déterminer les coefficients associés. Avec R il existe une fonction magique, qui nous évite d'y aller à tâtons, c'est la fonction "auto.arima()". Cette fonction nous permettra de tester des dizaines de combinaisons (p,q) et de sélectionner automatiquement le meilleur modèle selon les critères de sélection de l'AIC. Critère dont nous avons défini précédemment, permettant de trouver le meilleur compromis entre qualité et complexité.

```
series: Rendement_N225
ARIMA(0,0,0) with non-zero mean

Coefficients:
      mean
      0.0093
s.e.    0.0041
```

```
Series: Rendement_ICLN
ARIMA(0,0,0) with zero mean

sigma^2 = 0.005845: log likelihood = 164.75
AIC=-327.5   AICc=-327.47   BIC=-324.54
```

Les résultats sont intéressants car ils expliquent que pour l'ETF ICLN, le code R a trouvé un ARIMA (0,0,0) avec une moyenne nulle, signifiant que l'indice est purement un choc aléatoire et centré sur zéro, le passé n'explique rien.

Pour le nikkei 225, l'interprétation est légèrement différente. Ici aussi l'arima est (0,0,0), mais la moyenne est non nulle et signifie simplement que la série est centrée autour d'une moyenne de 0.93%.

3ième étape : Le diagnostic (Validation)

C'est que l'on retrouve la nature la plus proche des tests que l'on a effectués. Pour cela nous utiliserons le test de Ljung-Box avec comme étape de validation :

- H_0 , les résidus sont indépendants et donc il y a absence d'autocorrélation, soit un bruit blanc parfait.
- H_1 , les résidus sont autocorrélés

La règle de décision ressemble beaucoup à celle du test ARCH. Nous calculons une p-value et on la compare avec le degré de confiance, soit 5%. Si la p-value est supérieure à 0.05, alors on accepte H_0 .

Pour cela nous utiliserons la fonction "Box.test()" dans R.


```
data: Modele_N225$residuals
X-squared = 11.807, df = 12, p-value = 0.4613
```

```
data: Modele_ICLN$residuals
X-squared = 4.5385, df = 12, p-value = 0.9716
```

Ici on voit, qu'à partir des résultats les deux indices sont validés et ils n'ont donc pas d'autocorrélations, la p-value est bien supérieur à 0.05. Ainsi les résidus restants sont donc des bruits parfaits et le modèle décrit bien qu'il n'y plus aucune information à exploiter.

L'étape 4 : la Prédiction

Une fois le modèle validé, on l'utilise pour déterminer les valeurs futures. Dans notre cas nous essayerons avec un horizon de $h = 6$ mois. Nous utilisons la fonction "forecast" sur R.



L'interprétation graphique nous permet de comprendre que l'algorithme nous dit que puisque que le modèle est imprévisible alors il suppose que les valeurs prédites soit celle de sa moyenne historique. Les zones gris foncé et claire, détermine l'intervalle de confiance et nous permet d'avoir une idée de sa potentielle volatilité.

Question 5 :

À l'aune de ces résultats, nous pouvons affirmer avec robustesse l'hypothèse d'efficience informationnelle au sens faible de Fama (1965) pour nos indices de références, soit le Nikkei 225 et l'ETF Ishares Global Clean Energy (ICLN).

Dans un premier temps, nous avons effectué le test de Dicker-Fuller augmenté, qui nous a permis de déterminer la stationnarité de nos deux indices, le tout sans besoin de différenciation soit $I(0)$, avec la méthode des log-rendements. De ce fait nous savons la stationnarité des rendements et intuitivement que les prix ont donc une racine unitaire et sont donc stationnaire avec une différence de 1 ordre. Ceci implique que pour tout choc subi par les prix à l'instant t , a un effet permanent. Ce qui est une première condition à l'acceptation de l'hypothèse d'efficience des marchés au sens faible de FAMA. Par la suite nous avons appliqué le test ARCH à deux horizons différents de court terme, confirmant l'homoscédasticité conditionnelle de la variance des rendements. Ces résultats nous confortent dans l'idée que les risques associés à ses actifs sont temporellement indépendants.

Enfin nous avons mis en œuvre la méthode de Box-Jenkins avec le test de Box-Ljung. Cette étape nous a permis d'apporter la preuve empirique décisionnaire. Pour les deux indices, nous obtenons un modèle ARIMA (0.0.0), prouvant que ni les paramètres autorégressifs et de moyennes mobile, parviennent à expliquer les résultats futurs à partir de ceux du passé. Ni les erreurs ou les rendements sont utiles à la prévision. Les rendements du passé sont simplement des bruits blancs parfaits et le test de box-Ljung confirme bien l'absence d'indépendance des résidus.

Ainsi en se basant sur la littérature financière, toutes ces conclusions impliquent bien que l'ensemble de l'information est instantanément et parfaitement incorporé dans le cours actuel des actifs. Puisqu'il n'existe aucune mémoire linéaire ou non linéaire, alors la prévision se traduit simplement par la moyenne historique des indices. Il est donc impossible de générer des rendements anormaux ou de surperformer le marché en se basant sur l'historique du cours des actions. Nous pouvons donc conclure que nos indices de références tel que le Nikkei225 et l'ICLN corrobore parfaitement le modèle de marche aléatoire et donc de la théorie d'efficience informationnelles des marchés sous sa forme faible.

Références

Fama, E., 1965. The Behavior of Stock Market Prices. Journal of Business 38, 34–105.

Lardic, S., Mignon, V., 2006. L'efficience informationnelle des marchés financiers. Repères. chapitre 2. pp. 27–45.

Stachowiak, C., 2004. Prévisibilité des rentabilités boursières. Economie et Prévision , 71–85.